

RAG数据分析与设计说明

1. 任务背景与目标

本阶段任务是面向医学专业知识生成 LLM 的 RAG 系统做数据加载与评估准备，重点不是训练模型，也不是开发完整问答系统，而是确认 PMC OA oa_comm/xml 文献能否被稳定解析、清洗、切分、向量化并用于后续检索增强生成。

本报告基于本地已下载的 PMC OA Bulk oa_comm/xml 小样本，共 3028 篇 XML 文献。分析范围覆盖字段完整性、基础质量、metadata 可用性、医学领域语言特征、token 长度分布、文本分割策略，并额外完成了全文 routed chunk + all-MiniLM Chroma 规模验证。

本报告引用的阶段性说明文档包括：

```
outputs/docs/02_field_quality_strategy_notes_limit3028.md
outputs/docs/03_token_length_strategy_notes_limit3028.md
outputs/docs/04b_fulltext_domain_understanding_limit3028.md
outputs/docs/06_full_text_split_strategy_notes_limit3028.md
outputs/docs/08_fulltext_chroma_routed_minilm_report_limit3028_routed_minilm.md
```

2. 数据来源与加载方式

数据来源为 NCBI PMC OA Bulk deprecated 目录下的 oa_comm/xml：

```
https://ftp.ncbi.nlm.nih.gov/pub/pmc/deprecated/oa_bulk/oa_comm/xml/
```

实际处理结果：

指标	数值
目标 XML 数	3028
实际选择 XML 数	3028
解析成功	3028
解析失败	0
Dataset 行数	3028

核心输出文件：

```
outputs/records/pmc_records_limit3028.csv
outputs/records/pmc_records_limit3028.jsonl
outputs/tables/parse_summary_limit3028.csv
outputs/docs/01_parse_strategy_notes_limit3028.md
```

3. 数据规模与字段结构

每篇文献解析为以下字段：

```
record_id
source_file
title
abstract
body
journal
pub_date
pub_year
pmid
pmcid
article_type
text_title_abstract
text_full
```

字段用途如下：

字段	作用
title	增强检索文本，提供主题上下文
abstract	摘要级 RAG 的核心文本
body	全文 RAG 的主要文本来源
journal	后续按期刊过滤的 metadata
pub_date / pub_year	后续按时间过滤的 metadata
pmid	PubMed 原文追溯和 citation
pmcid	PMC 原文追溯和 citation
source_file	本地数据溯源和调试
article_type	区分 research article、review、letter 等类型

4. 字段完整性分析

字段缺失统计如下：

字段	非空数量	缺失数量	缺失率
title	3028	0	0.00%
abstract	2775	253	8.36%
body	3028	0	0.00%
journal	3028	0	0.00%
pub_date	3028	0	0.00%
pub_year	3028	0	0.00%
pmid	2753	275	9.08%
pmcid	3028	0	0.00%
article_type	3028	0	0.00%

abstract 缺失率为 8.36%，已经高于 1%，不能简单忽略。由于所有样本均有 body，缺失 abstract 的样本仍有正文可用。

对应结果表：

```
outputs/tables/missing_rate_limit3028.csv
outputs/docs/02_field_quality_strategy_notes_limit3028.md
```

清洗策略：

情况	策略	原因
abstract 存在	使用 title + abstract 作为摘要级检索文本	信息密度高，长度相对可控
abstract 缺失但 body 存在	使用 title + body 的前若干段或 introduction 替代摘要	避免丢弃 253 篇文献
title 缺失	当前未发生；若后续出现则保留正文，但降低 title 权重	title 对检索主题很重要
body 缺失	当前未发生；若后续出现则只进入摘要级库	全文 RAG 依赖 body
pmid 缺失	使用 pmcid/source_file 作为追溯 fallback	pmcid 当前 100% 可用

5. 基础质量分析

基础质量统计如下：

指标	数值
总记录数	3028
极短 abstract	318
空 title	0
空 abstract	253
空 body	0
编码错误	0
title + abstract 重复	0
pmid 重复	0
pmcid 重复	0
quality_decision = keep	2710
quality_decision = keep_with_warning	318

质量结论：

- 当前 XML 文本没有发现明显编码错误。
- 没有发现重复 title + abstract，也没有重复 pmid/pmcid。
- 318 篇被标记为 keep_with_warning，主要原因是 abstract 为空或过短。
- 所有 3028 篇均有正文，因此不建议在数据准备阶段直接丢弃 abstract 缺失样本。

对 RAG 的影响：

- 摘要级库可优先使用 keep 样本。
- keep_with_warning 样本仍可保留，但应通过正文前段或章节文本增强。
- 后续正式入库时应保留 quality_decision 作为 metadata，便于检索调试和质量分析。

对应结果表：

```
outputs/tables/quality_summary_limit3028.csv
outputs/tables/quality_flags_limit3028.csv
```

6. Metadata 可用性分析

metadata 可用率如下：

字段	可用率	后续用途
title	100.00%	检索文本增强、结果展示
journal	100.00%	期刊过滤
pub_year	100.00%	时间过滤
pmid	90.92%	PubMed citation/ source tracking
pmcid	100.00%	PMC citation/ source tracking
source_file	100.00%	本地溯源和调试

因此，当前数据已经支持后续实现类似：

```
检索近 5 年某一期刊上的文献
```

需要注意：journal 和 pub_year 在当前样本中可用率高，但如果后续扩展到更多 PMC shard，仍需要继续监控字段缺失和期刊名规范化问题。pmid 缺失率为 9.08%，引用追溯时应优先使用 pmcid，有 pmid 时再补充 PubMed 链接。

对应结果表：

```
outputs/tables/metadata_summary_limit3028.csv
```

7. 领域语言特性分析

本阶段对全文进行了领域内容理解分析，而不是只看摘要。全文抽样按 full_token_len 分为 short、medium、long 三组，每组抽样 8 篇，共 24 篇，人工阅读文件为：

```
outputs/samples/fulltext_stratified_sample_for_review_limit3028.md
outputs/samples/fulltext_stratified_sample_limit3028.jsonl
```

7.1 结构特点

全文结构分析结果：

指标	数值
有任意正文 section title 的文献	2695 / 3028
section title 覆盖率	89.00%
IMRaD core 比例	67.10%
包含 Conclusion/Summary 的结构比例	52.10%

常见正文 section title:

section title	出现次数
background	1982
discussion	1910
results	1825
methods	1643
authors' contributions	1602
conclusions	1392
competing interests	1047
pre-publication history	734
introduction	489
conclusion	471
supplementary material	401
materials and methods	391

结论是：研究型医学论文整体结构较清晰，但并非所有文献都严格使用 Introduction / Methods / Results / Discussion 四个标题。后续章节识别应兼容 Background、Materials and methods、Results and discussion、Conclusion、Summary、Case presentation 等变体。

7.2 摘要结构化标记

摘要中结构化标记统计如下：

标记	数量	比例
BACKGROUND	1967	64.96%
OBJECTIVE	147	4.85%
METHODS	1245	41.12%
RESULTS	1946	64.27%
CONCLUSIONS	1166	38.51%
INTRODUCTION	22	0.73%
DISCUSSION	79	2.61%

7.3 术语、缩写与高频词

全文 top 缩写包括：

缩写	次数
DNA	10605
RNA	6303
PCR	4551
II	3131
HIV	2915
CI	2057
SD	1801
CA	1561
PBS	1513
HIV-1	1509
GFP	1461
CD4	1378

全文高频 unigram：

term	count
cells	34872
data	31377
genes	22852
patients	22417
expression	20739
gene	19997
cell	19968
analysis	19574
protein	18363
different	14972
health	13085
time	12764

全文高频 bigram:

term	count
gene expression	3689
united states	1937
amino acid	1881
cell lines	1850
health care	1611
statistically significant	1382
amino acids	1330
statistical analysis	1208
breast cancer	1128
patients who	1126

领域语言特点可以概括为:

- 缩写密度高, 且包含疾病、基因、蛋白、检测方法和统计术语。

- 同一概念可能存在缩写、全称、连字符写法和近义表达，例如 HIV/AIDS/human immunodeficiency virus、PCR/polymerase chain reaction。
- 文本信息密度高，一句话中常同时包含研究对象、干预、检测指标、统计量和限定条件。

对后续 RAG 的影响：

- query rewrite 应支持缩写和全称双向扩展。
- prompt 应要求保留原始医学术语、数值和限定条件。
- 回答应携带 PMCID/PMID 或 source_file，支持 citation/source tracking。

领域内容分析对应产物：

```
outputs/docs/04b_fulltext_domain_understanding_limit3028.md
outputs/tables/fulltext_abbreviation_top50_limit3028.csv
outputs/tables/fulltext_high_freq_unigrams_limit3028.csv
outputs/tables/fulltext_high_freq_bigrams_limit3028.csv
outputs/tables/fulltext_high_freq_trigrams_limit3028.csv
outputs/tables/fulltext_concept_variants_limit3028.csv
```

8. 文本长度分布分析

使用 sentence-transformers/all-MiniLM-L6-v2 对应 tokenizer 统计 token 长度，并以 512 tokens 作为 embedding 输入上限参考。

长度统计结果表：

```
outputs/tables/token_length_records_limit3028.csv
outputs/tables/token_length_stats_limit3028.csv
outputs/docs/03_token_length_strategy_notes_limit3028.md
```

8.1 title + abstract

指标	数值
count	3028
mean	315.30
median	336
max	952
p75	430
p90	519
p95	570.65
p99	676
超过 512 tokens	328
超过 512 比例	10.83%

结论：title + abstract 大部分较短，但仍有约 10.83% 超过 512 tokens。摘要级 RAG 不能完全无脑整体入库，应对长尾摘要做切分。

图 1 展示 title + abstract token 长度分布：





图 2 展示 title + abstract token 长度箱线图：




8.2 full text

指标	数值
count	3028
mean	6019.98
median	5503
max	25782
p75	8030.25
p90	10805.20
p95	13091.25
p99	18109.17
超过 512 tokens	3000
超过 512 比例	99.08%
超过 1024 tokens	2772
超过 1024 比例	91.55%

结论：全文几乎都超过 embedding 输入上限，不能整体入库，必须切分。

图 3 展示全文 token 长度分布：



9. 文本分割策略设计

本阶段比较三类策略：

策略	适用条件	优点	缺点
整体不分割	文本短于 embedding 上限	上下文完整，实现简单	超长文本会截断或报错
重叠滑动窗口	有长尾文本或无章节结构	稳定控制 chunk 长度	可能切断语义，引入重复
语义章节分割	正文有明确章节标题	保留论文结构，metadata 更清晰	依赖 XML 结构，处理更复杂

9.1 摘要级分割策略

对 title + abstract：

策略	条件	文献数
整体不分割	≤ 512 tokens	2700
重叠滑动窗口	> 512 tokens	328

建议：摘要级 RAG 使用 title + abstract，其中 2700 篇整体入库，328 篇用 RecursiveCharacterTextSplitter 切分。

9.2 全文分割策略

对 text_full:

策略	条件	文献数
整体不分割	full text <= 512 tokens	28
语义章节优先	full text > 512 且 XML 有 section title	2695
重叠滑动窗口兜底	full text > 512 且无 section title	305

全文分割策略：

```
whole_document_under_512:
    28 篇全文整体保留

semantic_section:
    2695 篇按 XML 顶层章节切分，保留 section_title metadata

recursive_fallback_no_section:
    305 篇无明确章节标题，使用 RecursiveCharacterTextSplitter 兜底
```

参数：

```
chunk_size = 400
chunk_overlap = 80
whole_doc_token_limit = 512
embedding_model = sentence-transformers/all-MiniLM-L6-v2
```

选择理由：

- 400 tokens 能控制在 all-MiniLM 的 512 tokens 限制内。
- 80 tokens overlap 有助于缓解跨句、跨段信息割裂。
- 章节优先能保留医学论文的 Background、Methods、Results、Discussion 等结构。
- 无章节样本用滑动窗口兜底，保证所有文献都能处理。

切分策略结果表与说明文档：

```
outputs/tables/full_text_split_strategy_summary_limit3028.csv
outputs/tables/full_text_section_analysis_limit3028.csv
outputs/tables/full_text_section_title_top50_limit3028.csv
outputs/docs/06_full_text_split_strategy_notes_limit3028.md
```

10. 全文 Chroma 规模验证

虽然本阶段主任务是数据加载与评估，但为了验证全文分割策略可落地，额外完成了 3028 篇全文 routed chunk + all-MiniLM Chroma 规模验证。

正式验证报告：

```
outputs/docs/08_fulltext_chroma_routed_minilm_report_limit3028_routed_minilm.md
```

验证口径：

route	records	chunks	chunks/篇 mean	chunks/篇 median	chunks/篇 p95
whole_document_under_512	28	28	1.00	1	1
semantic_section	2695	72879	27.04	26	49
recursive_fallback_no_section	305	1369	4.49	4	8

整体写入结果：

指标	数值
输入文献	3028
总 chunks	74276
Chroma collection count	74276
chunks/ 篇 mean	24.53
chunks/ 篇 median	24
chunks/ 篇 p95	47
chunk token p95	401
切分耗时	241.88 秒
模型加载耗时	0.16 秒
Chroma 写入耗时	905.92 秒
总耗时	1149.14 秒，约 19.2 分钟
向量库大小	985.91 MB

Chroma 目录：

```
outputs/chroma_fulltext_limit3028_routed_minilm
```

正式 Chroma 验证产物：

```
outputs/docs/08_fulltext_chroma_routed_minilm_report_limit3028_routed_minilm.md
outputs/tables/fulltext_chroma_routed_minilm_summary_limit3028_routed_minilm.csv
outputs/tables/fulltext_chroma_routed_minilm_route_summary_limit3028_routed_minilm.csv
outputs/tables/fulltext_chroma_routed_minilm_manifest_limit3028_routed_minilm.csv
outputs/tables/fulltext_chroma_routed_minilm_query_results_limit3028_routed_minilm.csv
outputs/chroma_fulltext_limit3028_routed_minilm/
```

本次验证说明：

- 3028 篇全文可以在本地完成 chunk、embedding 和 Chroma 写入。
- 全文库约 986 MB，说明 50GB 数据盘可以支持当前小样本和中小规模扩展。
- 后续扩展到更多文献时，主要瓶颈将是磁盘、embedding 时间、向量索引大小，而不是 LLM 推理显存。

11. 检索 sanity check

使用正式全文 Chroma 库执行 top-k 检索，部分结果如下：

query	top result
Plasmodium falciparum intraerythrocytic developmental cycle transcriptome	pmc_000001, Introduction / title+abstract, 匹配 Plasmodium falciparum transcriptome
pRb inactivation mammary cells tumor initiation progression	pmc_000089 和 pmc_000068, 匹配 pRb / tumor / mammary cells
type 2 diabetes high protein diet insulin concentration	pmc_001051, Results, 匹配 type 2 diabetes、protein diet、insulin/glucose response
SARS coronavirus spike protein trafficking	pmc_002582, Title and abstract, 匹配 SARS coronavirus spike protein trafficking

完整结果：

```
outputs/tables/fulltext_chroma_routed_minilm_query_results_limit3028_routed_minilm.csv
```

全文 chunk + Chroma 检索链路可用，且能返回与 query 主题相关的文献和章节。

检索 sanity check 中，每条结果均保留了 record_id、route、chunk_strategy、section_title、source_file 和 snippet，可用于后续人工判断召回结果是否相关，也可为下一阶段 answer citation 设计提供字段基础。

12. 当前阶段结论

本阶段已完成以下工作：

1. 成功解析 3028 篇 PMC OA oa_comm/xml 文献，失败数为 0。

- 2. 建立本地 Dataset pipeline，形成 CSV/JSONL 结构化 records。
- 3. 完成字段完整性、缺失率、基础质量和 metadata 可用性分析。
- 4. 确认 journal、pub_year、pmcid、source_file 适合作为 RAG metadata。
- 5. 确认 abstract 缺失率为 8.36%，需要 body/introduction 替代策略。
- 6. 完成摘要和全文 token 长度分析，确认全文必须切分。
- 7. 完成医学全文领域语言分析，包括结构、缩写、高频术语和同义表达。
- 8. 制定摘要级和全文级分割策略。
- 9. 完成 3028 篇全文 routed chunk + all-MiniLM Chroma 规模验证。

初始 RAG 数据构造：

层级	文本	策略
摘要级 RAG	title + abstract	2700 篇整体，328 篇滑动窗口
全文 RAG	title + abstract + body	28 篇整体，2695 篇文章优先，305 篇滑动窗口兜底
metadata	journal, pub_year, pmid, pmcid, source_file, article_type, section_title	用于过滤、追溯和 citation

13. 关键产物路径

```
outputs/records/pmc_records_limit3028.csv
outputs/tables/missing_rate_limit3028.csv
outputs/tables/quality_summary_limit3028.csv
outputs/tables/metadata_summary_limit3028.csv
outputs/tables/token_length_stats_limit3028.csv
outputs/tables/full_text_split_strategy_summary_limit3028.csv
outputs/docs/04b_fulltext_domain_understanding_limit3028.md
outputs/docs/06_full_text_split_strategy_notes_limit3028.md
outputs/docs/08_fulltext_chroma_routed_minilm_report_limit3028_routed_minilm.md
outputs/tables/fulltext_chroma_routed_minilm_summary_limit3028_routed_minilm.csv
outputs/tables/fulltext_chroma_routed_minilm_route_summary_limit3028_routed_minilm.csv
outputs/tables/fulltext_chroma_routed_minilm_query_results_limit3028_routed_minilm.csv
outputs/chroma_fulltext_limit3028_routed_minilm/
```