

RAG数据分析与设计说明（153121篇 PMC OA）

1. 任务背景与目标

本阶段任务是面向医学专业知识生成 LLM 的 RAG 系统做数据加载、数据评估和文本分割策略设计。mentor 反馈原先 3028 篇样本规模偏小，因此本轮将分析范围扩展到本地已下载的 153121 篇 PMC OA oa_comm/xml 文献，重新完成字段完整性、基础质量、metadata 可用性、医学领域语言特征、token 长度分布和文本分割策略分析。

本报告对应的正式产物前缀为 limit153121。核心脚本和输出包括：

```
scripts/10_analyze_oa_comm_153121.py
scripts/10_resume_oa_comm_153121.py
outputs/reports/RAG数据分析与设计说明_limit153121.md
outputs/tables/pmc_records_light_limit153121.csv
outputs/tables/fullscale_analysis_summary_limit153121.csv
outputs/samples/fulltext_stratified_sample_for_review_limit153121.md
```

2. 数据来源与加载方式

数据来源为 NCBI PMC OA Bulk deprecated 目录下的 oa_comm/xml：

```
https://ftp.ncbi.nlm.nih.gov/pub/pmc/deprecated/oa_bulk/oa_comm/xml/
```

本地数据目录：

```
data/pmc_oa_comm
```

本轮直接分析本地三片 XML 数据：

数据片	XML 数
PMC000xxxxxx	3028
PMC001xxxxxx	27518
PMC002xxxxxx	122575
合计	153121

实际处理结果：

指标	数值
目标 XML 数	153121
实际选择 XML 数	153121
解析成功	153121
解析失败	0
轻量全量表记录数	153121

核心输出文件：

```
outputs/tables/parse_summary_limit153121.csv
outputs/tables/pmc_records_light_limit153121.csv
outputs/tables/fullscale_analysis_summary_limit153121.csv
outputs/logs/10_resume_oa_comm_limit153121.log
```

3. 数据规模与字段结构

本轮每篇 XML 文献被解析为面向分析的轻量记录。主要字段如下：

字段	作用
record_id	本轮处理生成的内部记录 ID
doc_id	优先使用 PMID，否则使用 PMCID 等追溯 ID
source_file	本地 XML 文件路径，用于溯源和调试
title	检索文本增强和结果展示
journal	后续按期刊过滤的 metadata
pub_date / pub_year	后续按年份或时间范围过滤的 metadata
pmid	PubMed 原文追溯和 citation
pmcid	PMC 原文追溯和 citation
article_type	区分 research article、review、case report 等类型
title_abstract_token_len	title + abstract 的 tokenizer 长度
full_token_len	title + abstract + body 的 tokenizer 长度
quality_decision	基础质量标记
section_title_count	正文 XML section title 数量
recommended_split_strategy	本轮推荐的全文分割路由

轻量表路径：

```
outputs/tables/pmc_records_light_limit153121.csv
```

需要注意：轻量表中的 full_token_len 是对全文内容计算后的长度统计，但表内不保存全文本身。这样既保留了分析指标，也避免了不必要的磁盘膨胀。

4. 字段完整性分析

字段缺失统计如下：

字段	非空数量	缺失数量	缺失率
title	153101	20	0.01%
abstract	138489	14632	9.56%
body	133539	19582	12.79%
journal	153121	0	0.00%
pub_date	153121	0	0.00%
pub_year	153121	0	0.00%
pmid	147551	5570	3.64%
pmcid	153121	0	0.00%
article_type	153121	0	0.00%

abstract 缺失率为 9.56%，高于 1%，不能简单忽略。与 3028 小样本相比，15w 数据中还出现了 body 缺失，缺失率为 12.79%。因此，后续 RAG 数据构建需要区分摘要级和全文级可用性。

对应结果表：

```
outputs/tables/missing_rate_limit153121.csv
```

清洗策略建议：

情况	策略	原因
title 存在	保留并拼接到检索文本前部	title 提供主题上下文
title 缺失	保留正文或摘要，但结果展示时用 PMCID/source_file 兜底	仅 20 篇缺失，不应因此丢弃正文
abstract 存在	摘要级 RAG 使用 title + abstract	信息密度高，长度相对可控
abstract 缺失但 body 存在	保留到全文级流程，后续可用 introduction 或正文前段增强	避免丢弃 14632 篇文献
body 存在	进入全文级 RAG 候选	全文 RAG 的主要来源
body 缺失但 title/abstract 存在	只进入摘要级 RAG 或短文档流程	无法做章节级全文切分
title、abstract、body 均缺失	标记为 drop_no_text	无可检索文本
pmid 缺失	使用 pmcid/source_file 作为追溯 fallback	pmcid 当前 100% 可用

5. 基础质量分析

基础质量统计如下：

指标	数值
总记录数	153121
空 title	20
空 abstract	14632
空 body	19582
重复 pmid	32
重复 pmcid	0
quality_decision = keep	123356
quality_decision = keep_with_warning	24278
quality_decision = need_review	5472
quality_decision = drop_no_text	15

质量标记占比如下：

quality_decision	文献数	比例
keep	123356	80.56%
keep_with_warning	24278	15.86%
need_review	5472	3.57%
drop_no_text	15	0.01%

质量结论：

- keep 占 80.56%，大部分文献具备较完整的标题、摘要或正文。
- keep_with_warning 主要来自 abstract 缺失、过短或正文可用性不足等情况，不建议直接丢弃。
- need_review 占 3.57%，可在后续 chunk 生成时保留质量标记，便于抽样检查。
- drop_no_text 只有 15 篇，后续正式 chunk 数据集可以排除。
- pmcid 没有重复，适合作为稳定追溯字段；pmid 有少量重复或缺失，不能作为唯一主键。

对应结果表：

```
outputs/tables/quality_summary_limit153121.csv
```

对 RAG 的影响：

- 摘要级库可优先使用 keep 样本。
- keep_with_warning 可以保留，但需要在 metadata 中记录质量标记。
- need_review 样本不应在分析阶段删除，后续可通过质量抽样确定是否进入正式库。
- drop_no_text 没有可检索文本，实际 chunk 生成时应排除。

6. Metadata 可用性分析

metadata 可用率如下：

字段	可用率	后续用途	建议
title	99.99%	检索文本增强、结果展示	保留
journal	100.00%	期刊 metadata filter	保留
pub_year	100.00%	年份 metadata filter	保留
pmid	96.36%	PubMed 原文追溯	保留，但不能作为唯一主键
pmcid	100.00%	PMC 原文追溯	保留，优先作为追溯 ID
source_file	100.00%	本地溯源和调试	保留

对应结果表：

outputs/tables/metadata_summary_limit153121.csv

Top journal 分布：

journal	文献数	比例
British Journal of Cancer	19946	13.03%
PLoS ONE	14937	9.76%
Acta Crystallographica Section E: Structure Reports Online	9204	6.01%
BMC Bioinformatics	3594	2.35%
Environmental Health Perspectives	3567	2.33%
BMC Genomics	2944	1.92%
Emerging Infectious Diseases	2841	1.86%
PLoS Biology	2522	1.65%
BMC Public Health	2458	1.61%
BMC Cancer	2220	1.45%

Top publication year 分布:

pub_year	文献数	比例
2010	33777	22.06%
2009	33718	22.02%
2008	26298	17.17%
2007	15467	10.10%
2006	10957	7.16%
2005	7732	5.05%
2004	3841	2.51%
2003	1421	0.93%
1999	1323	0.86%
2002	1269	0.83%

Article type 分布:

article_type	文献数	比例
research-article	125231	81.79%
review-article	6484	4.23%
other	6076	3.97%
case-report	3079	2.01%
letter	2669	1.74%
editorial	1714	1.12%
correction	1254	0.82%
book-review	1225	0.80%
brief-report	1178	0.77%
news	1093	0.71%

metadata 结论：

- 当前 15w 数据已经支持后续实现按 journal、pub_year、article_type 等字段过滤。
- pub_year 分布集中在 2005-2010，说明这批 deprecated baseline 适合做方法验证和系统链路建设，但不能代表最新医学文献。
- pmcid 100% 可用，应作为 citation/source tracking 的主追溯字段。
- pmid 可用率为 96.36%，有 PMID 时可补充 PubMed 链接；缺失时用 PMCID。

7. 领域语言特性分析

本轮领域内容理解基于全文解析后的轻量统计和分层抽样，不只看摘要。抽样阅读文件为：

```
outputs/samples/fulltext_stratified_sample_for_review_limit153121.md
outputs/tables/fulltext_domain_sample_summary_limit153121.csv
```

抽样覆盖 short、medium、long 三个 full_token_len 区间，用于观察医学文本的信息密度、章节结构、术语缩写和后续 prompt 设计风险。

7.1 正文结构特点

全文结构统计：

指标	数值
总文献数	153121
有任意正文 section title 的文献	125852
section title 覆盖率	82.19%
IMRaD core 文献数	79546
IMRaD core 比例	51.95%
含 Conclusion/Summary 的 IMRaD 比例	32.43%
section title 数量均值	11.60
section title 数量中位数	11
section title 数量 p95	26
section title 数量最大值	253

常见正文 section title:

section title	出现次数
discussion	85357
results	78815
authors' contributions	57064
methods	53300
background	51776
conclusion	44912
introduction	43766
competing interests	43225
materials and methods	30296
supplementary material	25694
statistical analysis	19755
conclusions	16160
pre-publication history	15678
supporting information	13944
abbreviations	13295

对应结果表：

```
outputs/tables/full_text_section_analysis_light_limit153121.csv
outputs/tables/full_text_section_title_top80_limit153121.csv
```

结论是：15w 文献中多数正文具有可利用的 XML section title，但结构并不完全等同于标准 Introduction / Methods / Results / Discussion。后续语义章节分割需要兼容 Background、Materials and methods、Results and discussion、Conclusion、Summary、Case presentation、Statistical analysis 等变体。

7.2 摘要结构化标记

摘要中结构化标记统计如下：

标记	数量	比例
BACKGROUND	63162	41.25%
OBJECTIVE	6798	4.44%
METHODS	45438	29.67%
RESULTS	73936	48.29%
CONCLUSIONS	23826	15.56%
INTRODUCTION	5930	3.87%
DISCUSSION	3170	2.07%

对应结果表：

```
outputs/tables/structured_abstract_markers_limit153121.csv
```

这说明摘要中也存在明显结构化信号，但覆盖率不如正文 section title 稳定。摘要级切分不能只依赖大写结构标记；更稳妥的做法是按 token 长度判断，短摘要整体保留，长摘要再用滑动窗口兜底。

7.3 术语、缩写与高频词

全文高频 unigram：

term	count
cells	1696163
data	1352632
patients	1138683
cell	977460
expression	976870
analysis	903142
genes	849569
gene	805030
protein	760655
both	734934
only	666775
different	652666
time	578945
treatment	571512
group	556482

全文 top 缩写:

缩写	次数
DNA	416075
PCR	233934
RNA	229474
II	156397
CI	147073
HIV	123178
SD	93264
S1	91749
CA	90497
PBS	82240
OR	77932
CD4	76510
GFP	76175
III	75812
MB	66414

对应结果表：

```
outputs/tables/fulltext_high_freq_unigrams_limit153121.csv
outputs/tables/fulltext_abbreviation_top80_limit153121.csv
```

本轮为避免 15w 全文 bigram/trigram Counter 长尾导致运行极慢，正式全量报告采用轻量 lexical pass：保留全量 unigram、缩写、section title 和结构化摘要标记；不把全量 bigram/trigram 作为正式指标。相关占位文件记录了这个边界：

```
outputs/tables/fulltext_high_freq_bigrams_limit153121.csv
outputs/tables/fulltext_high_freq_trigrams_limit153121.csv
outputs/tables/fulltext_concept_variants_summary_limit153121.csv
```

领域语言特点可以概括为：

- 缩写密度高，包含疾病、基因、蛋白、检测方法和统计术语。
- 同一概念可能存在缩写、全称、连字符写法和近义表达，例如 HIV/AIDS/human immunodeficiency virus、PCR/polymerase chain reaction。
- 文本信息密度高，一句话中常同时包含研究对象、干预、检测指标、统计量和限定条件。

- 后续 query rewrite 应支持缩写和全称双向扩展。
- prompt 应要求保留原始医学术语、数值、比较关系和限定条件。
- 回答应携带 PMCID/PMID 或 source_file，支持 citation/source tracking。

8. Token 长度分布分析

本轮使用 sentence-transformers/all-MiniLM-L6-v2 对应 tokenizer 统计 token 长度，并以 512 tokens 作为 embedding 输入上限参考。

长度统计结果表：

```
outputs/tables/token_length_records_light_limit153121.csv
outputs/tables/token_length_stats_limit153121.csv
```

8.1 title + abstract

指标	数值
count	153121
mean	310.69
median	330
min	0
max	2366
p75	428
p90	509
p95	560
p99	667
超过 512 tokens	14735
超过 512 比例	9.62%
超过 1024 tokens	24
超过 1024 比例	0.02%

结论：title + abstract 大部分较短，但仍有约 9.62% 超过 512 tokens。摘要级 RAG 不能完全无脑整体入库，应对长尾摘要做切分。

图 1 展示 title + abstract token 长度分布：





图 2 展示 title + abstract token 长度箱线图：



8.2 full text

指标	数值
count	153121
mean	5658.86
median	5374
min	0
max	198807
p75	8364
p90	11433
p95	13549
p99	18364
超过 512 tokens	132157
超过 512 比例	86.31%
超过 1024 tokens	118444
超过 1024 比例	77.35%

结论：全文普遍超过 embedding 输入上限，不能整体入库。由于 82.19% 文献有正文 section title，全文处理应优先按语义章节切分；没有章节结构的长文档再使用重叠滑动窗口兜底。

图 3 展示全文 token 长度分布：





图 4 展示全文 token 长度箱线图：



9. 文本分割策略设计

mentor 给出的三类策略不是全局三选一，而是根据文献长度和结构进行条件路由：

策略	适用条件	优点	缺点
整体不分割	文本短于 embedding 上限	上下文完整，实现简单	超长文本会截断或报错
重叠滑动窗口	有长尾文本或无章节结构	稳定控制 chunk 长度	可能切断语义，引入重复
语义章节分割	正文有明确章节标题	保留论文结构，metadata 更清晰	依赖 XML 结构，超长章节仍需二次切分

9.1 摘要级分割策略

对 title + abstract:

策略	条件	文献数	比例
整体不分割	<= 512 tokens	138386	90.38%
重叠滑动窗口	> 512 tokens	14735	9.62%

建议：摘要级 RAG 使用 title + abstract，其中 90.38% 可整体入库；超过 512 tokens 的长尾摘要使用 RecursiveCharacterTextSplitter 切分。

9.2 全文分割策略

对 text_full:

策略	条件	文献数	比例	估算 chunks
整体不分割	full text <= 512 tokens	20964	13.69%	23673
语义章节优先	full text > 512 且 XML 有 section title	125562	82.00%	2700414
重叠滑动窗口兜底	full text > 512 且无 section title	6595	4.31%	26373
合计	-	153121	100.00%	2750460

全文分割策略：

```
whole_document_under_512:
    20964 篇短文档整体保留

semantic_section:
    125562 篇按 XML 章节切分, 保留 section_title metadata

recursive_fallback_no_section:
    6595 篇无明确章节标题, 使用 RecursiveCharacterTextSplitter 兜底
```

建议参数:

```
chunk_size = 400
chunk_overlap = 80
whole_doc_token_limit = 512
embedding_model = sentence-transformers/all-MiniLM-L6-v2
```

选择理由:

- 400 tokens 能控制在 all-MiniLM 的 512 tokens 限制内。
- 80 tokens overlap 有助于缓解跨句、跨段信息割裂。
- 章节优先能保留医学论文的 Background、Methods、Results、Discussion、Conclusion 等结构。
- 无章节样本用滑动窗口兜底, 保证所有可用文献都能处理。
- 对超长章节, 下周实际 chunk 阶段应先按章节形成语义单元, 再对超长章节做 recursive split。

切分策略结果表:

```
outputs/tables/full_text_split_strategy_summary_limit153121.csv
```

10. 当前阶段结论

本阶段已完成以下工作:

1. 成功解析 153121 篇 PMC OA oa_comm/xml 文献, 失败数为 0。
2. 生成 15w 轻量全量表, 不保存全文大字段, 保留统计和策略字段。
3. 完成字段完整性、缺失率、基础质量和 metadata 可用性分析。
4. 确认 journal、pub_year、pmcid、source_file 适合作为 RAG metadata。
5. 确认 abstract 缺失率为 9.56%, 需要正文或 introduction 兜底策略。
6. 确认 body 缺失率为 12.79%, 后续需区分摘要级和全文级可用样本。
7. 完成摘要和全文 token 长度分析, 确认全文通常必须切分。
8. 完成医学全文领域语言分析, 包括结构、缩写、高频术语和抽样阅读。
9. 制定条件路由式文本分割策略: 短文整体不分割、结构清晰长文按语义章节、无章节长文使用重叠滑动窗口兜底。
10. 明确本轮不生成 chunk、不做 Chroma、不生成 PDF; 实际文本块数据集属于下周任务。

初始 RAG 数据构造建议：

层级	文本	策略
摘要级 RAG	title + abstract	138386 篇整体，14735 篇滑动窗口
全文 RAG	title + abstract + body	20964 篇整体，125562 篇文章优先，6595 篇滑动窗口兜底
metadata	journal, pub_year, pmid, pmcid, source_file, article_type, section_title, quality_decision	用于过滤、追溯、citation 和质量调试

13. 关键产物路径

```
outputs/reports/RAG数据分析与设计说明_limit153121.md
outputs/tables/parse_summary_limit153121.csv
outputs/tables/pmc_records_light_limit153121.csv
outputs/tables/fullscale_analysis_summary_limit153121.csv
outputs/tables/missing_rate_limit153121.csv
outputs/tables/quality_summary_limit153121.csv
outputs/tables/metadata_summary_limit153121.csv
outputs/tables/token_length_stats_limit153121.csv
outputs/tables/token_length_records_light_limit153121.csv
outputs/tables/full_text_split_strategy_summary_limit153121.csv
outputs/tables/full_text_section_analysis_light_limit153121.csv
outputs/tables/full_text_section_title_top80_limit153121.csv
outputs/tables/structured_abstract_markers_limit153121.csv
outputs/tables/fulltext_high_freq_unigrams_limit153121.csv
outputs/tables/fulltext_abbreviation_top80_limit153121.csv
outputs/tables/fulltext_domain_sample_summary_limit153121.csv
outputs/samples/fulltext_stratified_sample_for_review_limit153121.md
outputs/figures/title_abstract_token_length_hist_limit153121.png
outputs/figures/title_abstract_token_length_box_limit153121.png
outputs/figures/full_text_token_length_hist_limit153121.png
outputs/figures/full_text_token_length_box_limit153121.png
```

14. 验证结论

验证项	结果
XML 总数	153121
解析成功 + 解析失败	153121
轻量全量表行数	153122 行，表头 + 153121 记录
字段缺失统计	已生成
token 长度统计	已生成
section / IMRaD 统计	已生成
高频 unigram / 缩写统计	已生成
图表 PNG	已生成
正式 Markdown 报告	已生成
chunk dataset	未生成
Chroma	未生成
PDF	未生成