

全文 Chunk 处理日志与统计报告 (limit153121)

1. 交付物完整性结论

本轮“文档解析与分割工作”的核心交付物已经齐全：

交付要求	当前状态	对应文件
文本块数据集	已生成	outputs/chunks/pmc_chunks_limit153121_part000.parquet 至 part051.parquet
数据集 manifest	已生成	outputs/chunks/pmc_chunks_limit153121_manifest.csv
JSONL 预览样例	已生成	outputs/samples/chunk_preview_limit153121_sample.jsonl
处理日志	已生成	outputs/logs/11_chunk_oa_comm_limit153121.log
统计表	已生成	outputs/tables/chunk_summary_limit153121.csv 等
excluded 文献表	已生成	outputs/tables/excluded_documents_limit153121.csv
质量验证报告	已生成	outputs/reports/文档解析与分割质量验证_limit153121.md
Markdown 预览	已生成	outputs/samples/chunk_preview_limit153121.md

2. 运行配置

配置项	数值
data_split	limit153121
输入目录	data/pmc_oa_comm
输入 XML 数	153121
tokenizer	sentence-transformers/all-MiniLM-L6-v2
tokenizer 缓存	hf_cache/hub/models--sentence-transformers--all-MiniLM-L6-v2/snapshots/1110a243fdf4706b3f48f1d95db1a4f5529b4d41
chunk_size	400
chunk_overlap	80
whole_doc_token_limit	512
batch_size	3000
chroma_created	false
embedding_created	false

3. 处理日志摘要

原始日志文件为:

```
outputs/logs/11_chunk_oa_comm_limit153121.log
```

日志显示全量处理正常结束，最后状态为 **DONE**。关键日志结果如下:

指标	数值
Input XML	153121
Chunked documents	133539
Excluded documents	19582
Total chunks	3057078
Chunk token p95	416
Token >512 chunks	0
Duplicate chunk IDs	0
Manifest	outputs/chunks/pmc_chunks_limit153121_manifest.csv

脚本运行阶段按 part 和 overall 同时输出进度、速度和 ETA。最后一个 part 为 part051，处理 doc index 153000–153120，说明 153121 篇 XML 已全部覆盖。

日志中的 Arrow sysctlbyname failed 信息来自 macOS sandbox 下的 CPU 信息探测警告，不影响 Parquet 读写和结果完整性。

4. 数据集输出结构

正式 chunk 数据集以 52 个 Parquet shard 保存：

```
outputs/chunks/pmc_chunks_limit153121_part000.parquet
...
outputs/chunks/pmc_chunks_limit153121_part051.parquet
```

Manifest 路径：

```
outputs/chunks/pmc_chunks_limit153121_manifest.csv
```

Manifest 覆盖情况：

指标	数值
part 数	52
manifest 文献数合计	153121
manifest chunk 数合计	3057078
Parquet 总大小	1801.509 MB
Parquet 总大小	1.759 GB
每 part chunk 数均值	58789.96
每 part chunk 数中位数	68362
每 part chunk 数最小值	2942
每 part chunk 数最大值	80908

最大 chunk part：

part_id	document_count	chunk_count	file_size_mb
8	3000	80908	47.440
27	3000	79874	48.117
32	3000	79142	46.594
28	3000	78669	46.601
29	3000	77276	46.100

最小 chunk part:

part_id	document_count	chunk_count	file_size_mb	说明
51	121	2942	1.747	最后剩余 part
11	3000	7292	4.315	该批可用正文或长文比例较低
46	3000	11845	4.215	该批 chunk 数较少
9	3000	13248	7.914	该批 chunk 数较少
10	3000	15618	9.127	该批 chunk 数较少

5. Chunk 字段结构

每条 chunk 至少包含以下字段:

字段	作用
chunk_id	全局唯一 chunk ID，格式为 {doc_id}::chunk_{chunk_index:05d}
text	最终用于 embedding/retrieval 的文本，包含 Title、Section、Text
doc_id	文献主 ID，优先使用 PMCID
chunk_index	文档内 chunk 序号，从 0 开始
total_chunks	当前文档实际生成 chunk 总数
source_title	原始标题 metadata
token_count	最终 chunk text 的 tokenizer token 数
source_file	原始 XML 文件路径
journal	期刊 metadata
pub_date / pub_year	出版时间 metadata
pmid	PubMed 追溯 ID
pmcid	PMC 追溯 ID
article_type	文章类型
section_title	XML section title 或 fallback section
section_title_norm	section_title 标准化文本
split_strategy	分割路由
quality_decision	质量标记
title_missing	标题是否缺失
body_missing	正文是否缺失
chunk_char_len	chunk 字符长度
section_index	section 序号
section_chunk_index	section 内 chunk 序号

最终 chunk text 格式为：

```
Title: {title_or_fallback}
Section: {section_title_or_strategy}
Text:
{chunk_body_text}
```

6. 总体处理规模

指标	数值
original_xml	153121
processed_documents	153121
chunked_documents	133539
excluded_documents	19582
total_chunks	3057078
token_count_over_512	0
token_count_le_zero	0
empty_text_chunks	0
duplicate_chunk_ids	0
doc_id_missing	0
source_title_missing	11
pmcid_missing	0
source_file_missing	0
non_continuous_doc_count	0
total_chunks_mismatch_doc_count	0
max_index_mismatch_doc_count	0

整体结论：所有输入 XML 均完成处理；有正文的文献进入全文 chunk dataset；无正文或无文本文献进入 excluded 表。chunk ID、doc ID、PMCID/source_file 追溯、chunk_index 连续性和 total_chunks 一致性均通过质量验证。

7. Excluded 文献统计

excluded_reason	文献数	说明
no_body_for_fulltext	19567	有 title/abstract 等文本但无正文；本轮只做全文级 chunk，因此不生成 chunk
drop_no_text	15	title、abstract、body 均无可文本
合计	19582	全部已记录到 excluded 表

excluded 表路径：

```
outputs/tables/excluded_documents_limit153121.csv
```

字段包括 doc_id、pmid、pmcid、title、source_file、excluded_reason、has_title、has_abstract、has_body、title_token_len、abstract_token_len、body_token_len、fallback_available、note。

8. 分割路由统计

split_strategy	文献数	chunk 数	文献占比	chunk 占比
semantic_section	124996	3027781	81.63%	99.04%
recursive_fallback_no_section	5699	26156	3.72%	0.86%
whole_document_under_512	2844	3141	1.86%	0.10%
no_body_for_fulltext	19567	0	12.78%	0.00%
drop_no_text	15	0	0.01%	0.00%

解释：

- semantic_section 是主路径，说明大多数有正文文献具备可用 XML section title。
- recursive_fallback_no_section 覆盖无明确 section title 的正文文献。
- whole_document_under_512 覆盖少量短正文文献；其中部分短文在最终 Title/Section/Text 包装后仍被拆为多个 chunk，因此文献数 2844、chunk 数 3141。
- no_body_for_fulltext 与 drop_no_text 只进入 excluded 表，不生成 chunk。

9. 文本块大小统计

9.1 chunks/doc 分布

指标	数值
count	133539
mean	22.89
median	22
p75	32
p90	42
p95	49
p99	67
max	741

平均每篇有正文文献生成约 22.9 个 chunks。p95 为 49，说明绝大多数文献的 chunk 数处于可控范围。最大值 741 来自超长文献 PMID:PMC2848993，标题为 Nomenclature for factors of the HLA system, 2010，属于长表/命名法类内容，不是索引错误。

9.2 chunk token_count 分布

指标	数值
count	3057078
mean	333.88
median	379
p75	397
p90	409
p95	416
p99	434
max	512

本轮最终以完整 chunk text 计算 token_count，即包含 Title、Section 和正文片段。所有 chunk 均满足 token_count <= 512，可作为下一阶段 all-MiniLM-L6-v2 embedding 输入。

10. Section Title 分布

Top section title 如下:

section_title	chunk_count
Results	853611
Discussion	426437
Methods	332761
Background	164022
Introduction	132707
Materials and Methods	132020
Results and Discussion	77467
Results and discussion	67210
Authors' contributions	57240
Materials and methods	51395
Conclusion	48363
Competing interests	42996
Supporting Information	30699
Supplementary Material	29329
recursive_fallback	26156

结论：主要 chunk 来自 Results、Discussion、Methods、Background、Introduction 等论文核心结构，语义章节保留效果良好。recursive_fallback 单独计数，便于后续抽查无 section title 文献的切分质量。

11. 质量验证结果

检查项	结果
chunk_id_global_unique	True
doc_id_missing_count	0
chunk_index_non_continuous_doc_count	0
total_chunks_mismatch_doc_count	0
token_count_over_512_count	0
empty_text_chunk_count	0
short_chunk_count_token_lt_20	69
garbled_chunk_count	10
source_title_missing_count	11
pmcid_missing_count	0
source_file_missing_count	0
semantic_section_without_section_title	0
recursive_fallback_configured_overlap	80
recursive_fallback_multi_chunk_doc_count	5699

质量结论：

- 核心结构一致性全部通过： chunk ID 唯一、 doc ID 不缺失、 chunk_index 连续、 total_chunks 正确。
- 所有 chunk 都满足 embedding token 上限： token_count > 512 = 0。
- 追溯字段完整： pmcid 和 source_file 均不缺失。
- 语义章节元数据完整： semantic_section chunk 均保留 section_title。

需要后续决策的少量质量标记：

问题	数量	建议
source_title_missing	11	已使用 [Missing title: PMID:...] fallback，可保留
garbled_chunk	10	embedding 前建议抽查，必要时过滤
token_count < 20	69	多为极短文献或声明类 section，可保留或后续降权

12. Quality Decision 分布

quality_decision	chunk 数
keep	3014465
keep_with_warning	42504
need_review	109

绝大多数 chunk 标记为 keep。keep_with_warning 主要对应标题缺失、摘要缺失、正文较短或轻微质量风险。need_review 数量很少，可在进入 embedding 前重点抽查。

13. 预览与抽样检查

预览文件：

```
outputs/samples/chunk_preview_limit153121.md
outputs/samples/chunk_preview_limit153121_sample.jsonl
```

Markdown 预览包含：

- whole_document_under_512 样本；
- semantic_section 样本；
- recursive_fallback_no_section 样本；
- 多 chunk 文献样本；
- title 缺失但保留的样本；
- chunk metadata 示例；
- 同一 doc_id 下连续多个 chunk 的示例。

14. 总结

limit153121 全文 chunk 数据集已经完成，且满足正式进入下一阶段 embedding 的主要技术条件：

- 输入覆盖完整；
- 有正文文献全部生成 chunk；
- 无正文文献全部进入 excluded 表；
- chunk text 均包含 Title/Section/Text 上下文；
- token_count 全部不超过 512；
- chunk_id 全局唯一；
- doc_id、PMCID、source_file 可追溯；
- chunk_index 与 total_chunks 一致；

- 统计、日志、预览和质量验证文件齐全。

本轮正式产物可以作为后续医学 RAG 向量化输入。