

医学 RAG 本地大模型环境准备与验证报告

日期: 2026-06-23

1. 项目目标

本阶段目标是为后续医学专业知识生成型 LLM / RAG 系统开发完成基础环境准备, 并验证关键技术链路是否可用。

当前阶段属于准备工作, 不进行完整 RAG 系统开发, 重点验证以下内容:

- 本地大语言模型能否正常运行
- GPU 与 PyTorch 环境是否可用
- Chroma 向量数据库是否能够写入和检索
- PMC OA 医学文献 XML 数据源是否能够引入和解析
- LangChain 是否能够调用本地 Ollama 模型

2. 技术方案

当前采用的技术路线如下:

- 云服务器: AutoDL
- 操作系统: Ubuntu 22.04
- GPU: NVIDIA GeForce RTX 4090 24GB
- CUDA / PyTorch: PyTorch 2.5.1+cu124
- 本地模型运行框架: Ollama
- 本地模型: Qwen3-8B Q4 量化版本
- RAG 框架: LangChain
- 向量数据库: Chroma
- Embedding 模型: sentence-transformers/all-MiniLM-L6-v2
- 医学文献数据源: NCBI PMC OA oa_comm/xml 小样本

项目目录:

```
/root/autodl-tmp/medical_rag
```

Ollama 模型目录:

```
/root/autodl-tmp/medical_rag/ollama_models
```

3. 项目结构

当前项目结构如下:

```
medical_rag/
├── .venv/
├── chroma_test_db/
├── data/
│   ├── pmc_oa_comm/
│   │   ├── oa_comm_xml.PMC000xxxxxx.baseline.2026-06-18.tar.gz
│   │   └── PMC000xxxxxx/
├── hf_cache/
├── ollama_models/
└── scripts/
    ├── check_gpu.py
    ├── parse_pmc_sample.py
    ├── test_chroma.py
    └── test_ollama_langchain.py
```

其中:

- .venv/: Python 虚拟环境
- ollama_models/: Ollama 本地模型存储目录
- hf_cache/: HuggingFace 模型缓存目录
- chroma_test_db/: Chroma 测试向量库目录
- data/pmc_oa_comm/: PMC OA 医学文献 XML 小样本数据
- scripts/: 本阶段环境验证脚本

4. 已完成工作

4.1 Python 与 PyTorch 环境

已创建 Python 虚拟环境:

```
/root/autodl-tmp/medical_rag/.venv
```

当前 Python 版本:

```
Python 3.12.3
```

当前 PyTorch 版本:

```
2.5.1+cu124
```

在 RTX 4090 有卡模式下, 已验证 PyTorch 可以识别 GPU。

验证结果包括:

```
CUDA available: True
GPU name: NVIDIA GeForce RTX 4090
GPU memory GB: 23.516...
```

4.2 Ollama 本地模型

已安装 Ollama, 并将模型存放在数据盘目录, 避免占用系统盘空间:

```
/root/autodl-tmp/medical_rag/ollama_models
```

已下载并验证本地模型:

```
qwen3:8b
```

通过 `ollama run qwen3:8b` 已确认模型可以正常进行中文问答。

4.3 Chroma 向量数据库验证

已编写并运行 Chroma 测试脚本:

```
scripts/test_chroma.py
```

测试流程:

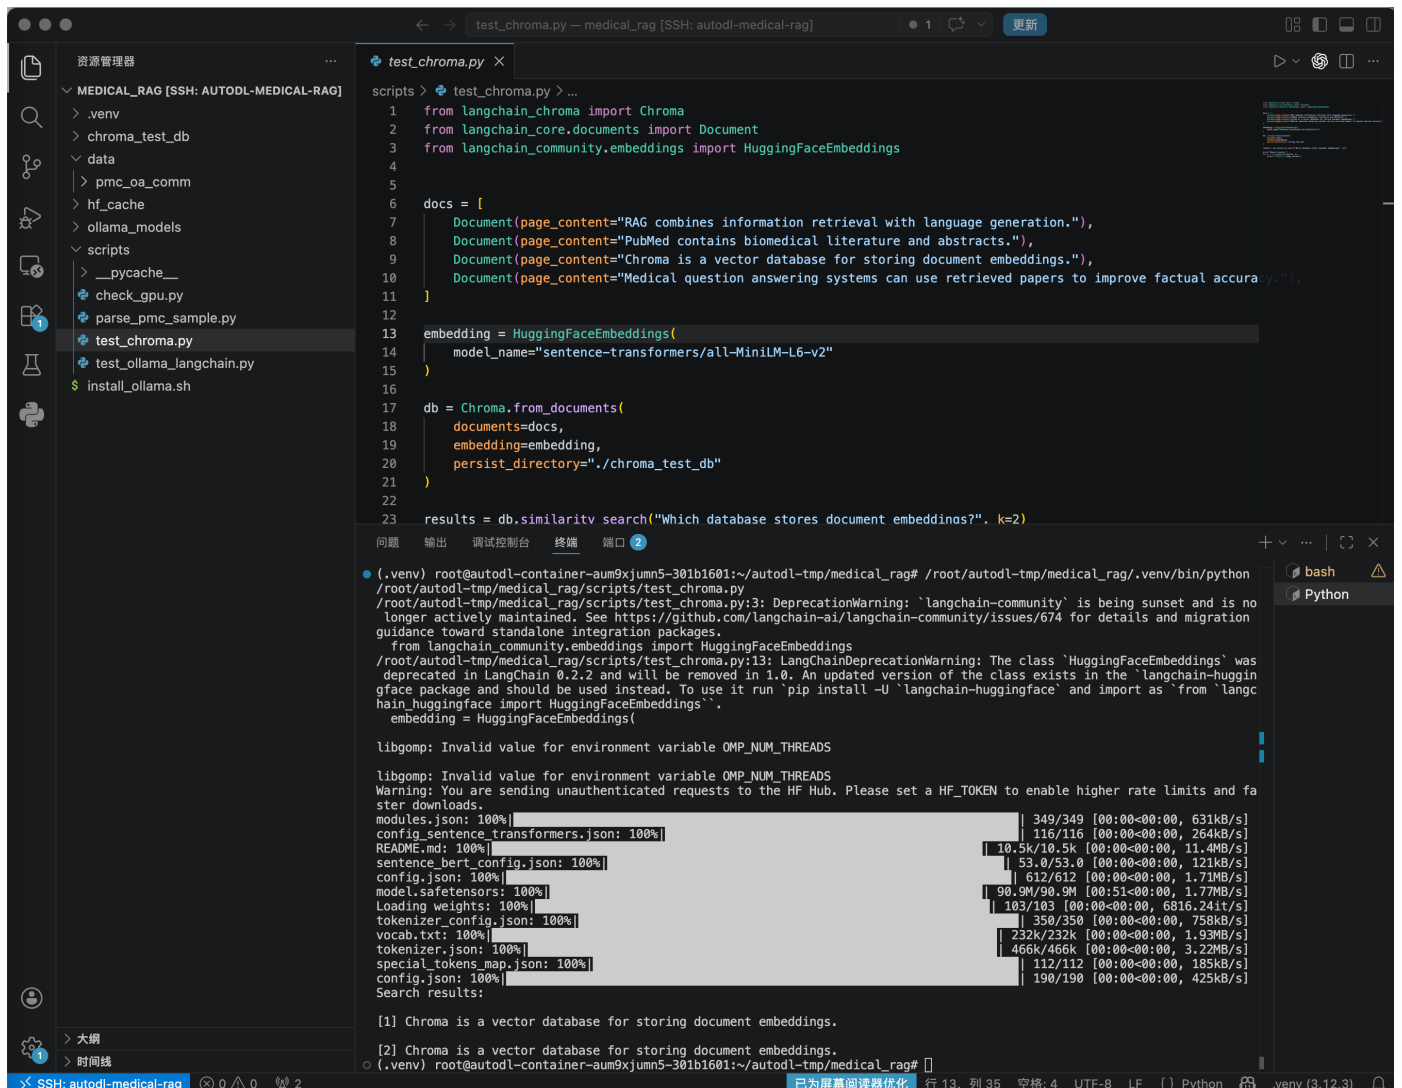
1. 构造少量测试文档
2. 使用 HuggingFace Embedding 模型生成文本向量
3. 写入 Chroma 本地向量数据库
4. 执行相似度检索

验证输出中成功返回:

Search results:

[1] Chroma is a vector database for storing document embeddings.

该结果说明 Chroma 的向量写入与检索流程已经打通。



```
test_chroma.py
1 from langchain_chroma import Chroma
2 from langchain_core.documents import Document
3 from langchain_community.embeddings import HuggingFaceEmbeddings
4
5 docs = [
6     Document(page_content="RAG combines information retrieval with language generation."),
7     Document(page_content="PubMed contains biomedical literature and abstracts."),
8     Document(page_content="Chroma is a vector database for storing document embeddings."),
9     Document(page_content="Medical question answering systems can use retrieved papers to improve factual accuracy."),
10 ]
11
12 embedding = HuggingFaceEmbeddings(
13     model_name="sentence-transformers/all-MiniLM-L6-v2"
14 )
15
16 db = Chroma.from_documents(
17     documents=docs,
18     embedding=embedding,
19     persist_directory="./chroma_test_db"
20 )
21
22 results = db.similarity_search("Which database stores document embeddings?", k=2)
23
24 [1] Chroma is a vector database for storing document embeddings.
25 [2] Chroma is a vector database for storing document embeddings.
```

4.4 PMC OA 医学文献数据源引入

已从 NCBI PMC OA oa_comm/xml 数据源下载小样本数据:

oa_comm_xml.PMC000xxxxxx.baseline.2026-06-18.tar.gz

解压后得到约 3028 个 XML 文件。

已编写并运行 XML 解析脚本:

scripts/parse_pmc_sample.py

脚本可以成功解析文献中的以下内容：

- Title
- Abstract preview
- Body preview

4.5 LangChain 调用 Ollama 验证

已编写测试脚本：

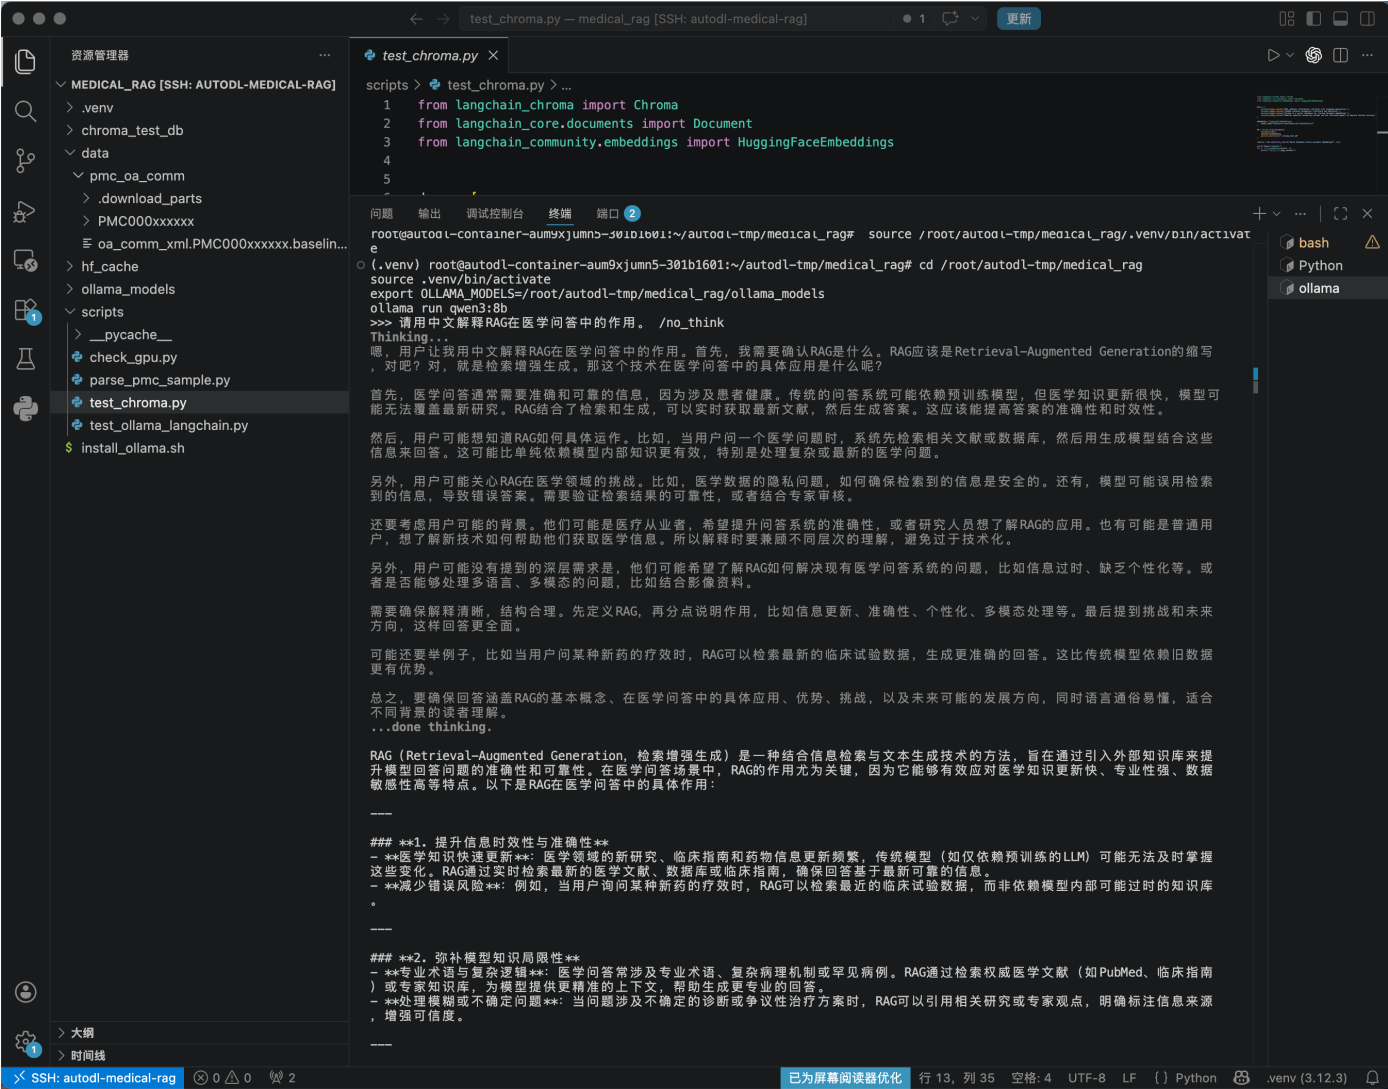
```
scripts/test_ollama_langchain.py
```

该脚本通过 LangChain 调用本地 Ollama 中的 qwen3:8b 模型，并成功生成中文回答。

LangChain 与本地 Ollama 模型之间的调用链路已经打通，后续可以在此基础上接入 Retriever，实现基础 RAG 问答流程。

4.6 本地模型中文问答验证

已通过 Ollama 直接与本地 Qwen3-8B 模型进行中文问答测试。模型能够正常加载并返回中文回答。



5. 当前验证结果汇总

验证项	当前状态	说明
AutoDL GPU 环境	已通过	有卡模式下识别 RTX 4090
PyTorch CUDA	已通过	CUDA available: True
Ollama 模型	已通过	ollama list 可看到 qwen3:8b
Chroma 向量库	已通过	可写入文档并完成相似度检索
PMC XML 数据源	已通过	已引入并解析 PMC OA XML 小样本
Ollama 本地问答	已通过	qwen3:8b 可正常生成中文回答
LangChain 调用 Ollama	已通过	可通过 LangChain 调用本地模型

6. 当前结论

目前已完成医学 RAG 项目前期环境准备与基础验证工作。

当前环境已经具备以下能力：

- 使用 RTX 4090 运行本地大语言模型
- 通过 Ollama 管理和调用 Qwen3-8B 模型
- 使用 LangChain 调用本地模型
- 使用 Chroma 存储和检索文本向量
- 引入并解析 PMC OA 医学文献 XML 数据